

Лабораторная работа №1. Аналитика данных на Python

1. Чтение файла и работа с датасетом

Необходимо прочитать файл taxi.csv, размещенный на ресурсе:

https://drive.google.com/u/0/uc?id=1P08K885c5M81d7EuWQeHv_OfPuW-bnO_

После чего отфильтровать датасет по поездкам только за выходные, а затем отдельно вывести общее количество поездок по месяцам.

2. Создание df

Дата-фрейм будет состоять из 10000 строк и 5 колонок.

Необходимо создать и заполнить данными каждую из колонок.

1-я колонка - user_id. Длина user_id должна равняться 15-ти символам и состоять из случайной комбинации следующих символов: "1234567890abcdefghijklmnopqrstuvwxyz". Комбинации каждого id в df формируются рандомно.

2-я колонка - номер заказа. Случайные значения лежат в диапазоне от 1 до 10.

3-я колонка - время доставки. Значения берутся из нормального распределения со средним 1440 и стандартным отклонением в 200.

4-я колонка - общая стоимость заказа. Значения берутся из экспоненциального распределения с параметром лямбда = 1, смещённого на +1.

5-я колонка - retention - день жизни покупателя, в который он совершил заказ. Сгенерировать значения 1,2,3,4,5 с соответствующими вероятностями 0.35, 0.25, 0.2, 0.15, 0.05.

В случае дублей user_id, оставьте только первую из дублирующихся записей.

3. Дополнение df

- Добавьте новый столбец - для всех строк исходного дата-сета, сгруппированных по номеру заказа, присвойте среднее значение времени доставки по группе.
- Определите сегмент, к которому относится заказчик, на основании номера заказа, который у него указан. Определённый сегмент присвойте каждому пользователю в новом столбце. Сегмент состоит из диапазона заказов по 3. Итоговые лейблы сегментов в новом столбце должны выглядеть так: "1-3", "4-6" и т.д.

4. Исследование df

- Посчитайте или покажите моду, медиану, среднее, дисперсию и стандартное отклонение для 4-й колонки - суммы стоимости заказа.
- Постройте график, который наиболее полно, на ваш взгляд, описывает время доставки заказа в зависимости от его номера.
- В виде единой матрицы графиков построить графики распределения времени доставки для каждого номера заказа. Каждый отдельный график в матрице должен иметь свой цвет и на каждом из графиков максимум необходимо выделить любым цветом, отличным от основного цвета выбранного графика.

5. Кластеризация

- Любым удобным методом кластеризуйте пользователей, на основании переменных "время заказа" и "сумма заказа".
- Обоснуйте число выбранных кластеров и присвойте их значения пользователям в отдельном столбце.

6. A/B анализ

- Выберите два любых кластера пользователей и проведите их сравнение.