


ТЕХНОЛОГИИ ХРАНЕНИЯ БОЛЬШИХ ДАННЫХ

Введение

.....

Преподаватель

ЗУЕВ ИГОРЬ АЛЕКСЕЕВИЧ (iazuev@gmail.com)



Организационная информация

Что сдаем: Курсовая работа + Зачет

Контрольные мероприятия:

- Проверочные работы по лекциям.
- Курсовая работа по итогам модуля.
- Письменный зачет по итогам модуля.

Правила:

Непонятно – спрашиваем.

К каждому семинару готовимся по итогам лекции на прошлой неделе.

Зачем всё это нужно?

Понять разницу между Data Engineer, ML Engineer и Data Scientist.

Получить первоначальные теоретические знания и практические навыки в области работы с Data.

Выбрать путь дальнейшего профессионального развития.

ОБЗОР МОДУЛЯ

- Методы многомерного статического анализа
- Технологии хранения и обработки данных
- Архитектура проектирования MPP-систем
- Программные средства для BIG DATA
- Hadoop – HDFS
- Spark
- Системы хранения больших данных
- Аналитические платформы и средства анализа
- Экосистема BIG DATA
- Data Analytics – технологии и методы анализа

BIG DATA

2008г. – Клиффорд Линч

Big Data («Большие данные») - совокупность инструментов и методов обработки структурированных и неструктурированных данных огромных объёмов из различных источников, подверженных постоянным обновлениям, в целях повышения качества принятия управленческих решений, создания новых продуктов и повышения конкурентоспособности.

Volume, Velocity, Variety, Veracity, Variability, Visualization, Value

CRISP-DM

Cross Industry Standard Process for Data Mining


- Бизнес-анализ (Business understanding)
- Анализ данных (Data understanding)
- Подготовка данных (Data preparation)
- Моделирование (Modeling)
- Оценка результата (Evaluation)
- Внедрение (Deployment)




CRISP-DM

Business Understanding/ Бизнес-анализ	Data Understanding/ Анализ данных	Data Preparation/ Подготовка данных	Modeling/ Моделирование	Evaluation/ Оценка решения	Deployment/ Внедрение
Determine Business Objectives/ Определение бизнес-целей Assess Situation/ Оценка текущей ситуации Determine Data Mining Goals/ Определение целей аналитики Produce Project Plan/ Подготовка плана проекта	Collect Initial Data/ Сбор данных Describe Data/ Описание данных Explore Data/ Изучение данных Verify Data Quality/ Проверка качества данных	Select Data/ Выборка данных Clean Data/ Очистка данных Construct Data/ Генерация данных Integrate Data/ Интеграция данных Format Data/ Форматирование данных	Select Modeling Techniques/ Выбор алгоритмов Generate Test Design/ Подготовка плана тестирования Build Model/ Обучение моделей Assess Model/ Оценка качества моделей	Evaluate Results/ Оценка результатов Review Process/ Оценка процесса Determine Next Steps/ Определение следующих шагов	Plan Deployment/ Внедрение Plan Monitoring and Maintenance/ Планирование мониторинга и поддержки Produce Final Report/ Подготовка отчета Review Project/ Ревью проекта

CRISP-ML





Человек, который изменил всё (2011)

Moneyball 16+

Менеджер-визионер пытается сделать из аутсайдеров чемпионов. Спортивная драма по сценарию Аарона Соркина