

ТЕХНОЛОГИИ ХРАНЕНИЯ БОЛЬШИХ ДАННЫХ

Многомерный Статистический Анализ

.....

Многомерный статистический анализ

Набор статических методов изучения многомерных статистических данных.

Позволяет находить скрытые и неочевидные закономерности в больших массивах данных и принимать на основе этих закономерностей управленческие решения.

Используется для Data Mining.

Многомерный статистический анализ

- **Факторный анализ**
- **Многомерное шкалирование**
- **Дискриминантный анализ**
- **Кластерный анализ**

Коэффициент корреляции

Коэффициент корреляции характеризует силу связи между переменными.

- **Может принимать значения от -1 до +1**
- **Знак коэффициента показывает направление связи (прямая или обратная)**
- **Абсолютная величина показывает тесноту связи**

Необходимо, чтобы у переменных была значительная изменчивость! Если сформировать выборку изначально однотипных особей, нечего надеяться выявить там корреляции.

Если мы не можем выделить такую зависимую переменную, которая функционально зависит от всех остальных, используем множественную корреляцию.

Факторный анализ: понятие

Факторный анализ – это процедура, с помощью которой большое число переменных, относящихся к имеющимся наблюдениям, сводят к меньшему количеству независимых влияющих величин, называемых факторами:

- в один фактор объединяются переменные, сильно коррелирующие между собой.**
- переменные из разных факторов слабо коррелируют между собой.**

Факторный анализ классифицирует признаки (переменные), описывающие наблюдения.

Фактор (Factor) – скрытая переменная, конструируемая таким образом, чтобы можно было объяснить корреляцию между набором имеющихся переменных.

Факторный анализ: назначение

Цель факторного анализа – сокращение числа переменных на основе их классификации и определения структуры взаимосвязей между ними.

Благодаря сокращению числа переменных вместо исходного набора переменных появляется возможность анализировать данные по выделенным факторам, число которых значительно меньше исходного числа взаимосвязанных переменных.

Смысл факторного анализа – измеряемые эмпирические показатели считаются следствием других, глубинных, скрытых от непосредственного измерения характеристик (скрытых переменных).

Факторный анализ: пример

Расчет прибыли от продаж компании.

Прибыль зависит от четырех основных факторов: объема продаж, ассортимента реализованной продукции, себестоимости продукции и цены реализации продукции.


С помощью факторного анализа можно рассчитать, как каждый из перечисленных факторов влияет на величину прибыли компании, и, исходя из полученных результатов, выработать пути максимизации прибыли.

Многомерный статистический анализ

Мотивы туристов, при выборе места отдыха за городом:

- близость к городу
- приемлемые цены
- близость водоема, леса
- уровень комфорта
- тишина, уединение
- хорошее питание
- наличие развлечений
- возможность отдыха с детьми
- возможность лечения, ухода за здоровьем

Факторный анализ: схема



F – общие факторы, каждый из которых влияет на определенную совокупность переменных

X – переменные, фиксируемые на основании ответов

Факторный анализ: условия

- Все признаки должны быть количественными переменными (интервальными либо метрическими).
- Число наблюдений должно быть минимум в два раза больше числа переменных. Оптимальное количество – 100+
- Выборка должна быть однородна.
- Исходные переменные должны быть распределены симметрично (нормальное распределение).
- Номинальные переменные должны быть переведены в дихотомические (переменные, имеющие только две категории).
- Между переменными должна быть ненулевая корреляция, но коэффициентов корреляции, близких единице, тоже быть не должно.

Факторный анализ: разновидности

1. Анализ главных компонент (principal component analysis)

- больше подходит, если основная цель – сократить число переменных в анализе

2. Анализ главных факторов (principal factor analysis)

- больше подходит для поиска структуры переменных, определения их иерархии

Методы:

- Невзвешенный МНК
- Обобщенный МНК
- Максимум правдоподобия
- Факторизация главной оси
- Альфа факторизация
- Анализ образов

Факторный анализ: этапы

Процедура факторного анализа состоит из четырех основных стадий:

- 1. Вычисление корреляционной матрицы для всех переменных, участвующих в анализе**
- 2. Извлечение факторов**
- 3. Выбор факторов и вращение факторов для создания упрощенной структуры**
- 4. Интерпретация факторов**

Факторный анализ: корреляционная матрица, R

Первая операция, которая производится при выполнении факторного анализа — вычисление корреляционной матрицы для переменных, участвующих в анализе.

	Я слушаю музыку каждый день	Мои музыкальные предпочтения однообразны. Я слушаю музыку одного стиля	Современная музыка лучше, чем классическая	Зарубежная музыка мне нравится больше, чем отечественная	Прослушивание музыки требует концентрации, ее нельзя слушать на ходу	Мои друзья слушают примерно такую же музыку, как и я	Фоновая музыка помогает мне лучше работать, учиться, делать повседневные дела	Я люблю музыкантов, которые могут выступать без фонограммы	В последнее время я слушаю музыку чаще, чем раньше
Я слушаю музыку каждый день	1,000	,038	-,010	,016	-,102	,079	,034	,023	,044
Мои музыкальные предпочтения однообразны. Я слушаю музыку одного стиля	,038	1,000	,058	-,051	-,045	,032	,115	-,069	-,028
Современная музыка лучше, чем классическая	-,010	,058	1,000	,100	,034	-,063	-,007	-,046	-,021
Зарубежная музыка мне нравится больше, чем отечественная	,016	-,051	,100	1,000	,058	-,070	-,027	-,042	,061
Прослушивание музыки требует концентрации, ее нельзя слушать на ходу	-,102	-,045	,034	,058	1,000	,005	-,031	,067	-,021

Факторный анализ: извлечение факторов

Извлечение фактора начинается с подсчета суммарного разброса значений всех участвующих в анализе переменных. Для этого «суммарного разброса» непросто подобрать логическую интерпретацию, однако он является вполне строго определенной математической величиной.

1. Извлечение факторов заключается в выборе взаимодействующих переменных, чья взаимная корреляция обуславливает наибольшую долю общей дисперсии. Эти переменные образуют первый фактор.
2. Затем первый фактор исключается и из оставшегося множества переменных снова выбираются те, чье взаимодействие определяет наибольшую долю оставшейся общей дисперсии. Эти переменные образуют второй фактор.
3. Процедура извлечения факторов продолжается до тех пор, пока не будет исчерпана вся общая дисперсия переменных.
4. После того как процедура извлекает каждый фактор, напротив его номера появляется собственное значение, которое пропорционально доле общей дисперсии, определяемой данным фактором.

Факторный анализ: метод главных компонент

Метод главных компонент основан на определении минимального числа факторов, вносящих наибольший вклад в дисперсию данных. Они называются главными компонентами.

Главные компоненты независимы. Выделение первой главной компоненты по максимальному вкладу в дисперсию признаков означает, что мы находим такое направление в пространстве признаков, которому соответствует максимальная дисперсия, т.е. наибольшая дифференциация, разброс объектов. Затем находится вторая главная компонента, ортогональная первой и дающая вновь наибольшую дифференциацию объектов, не объясненную первой компонентой и т.д.

После построения всех главных компонент (число которых равно числу признаков X) остаточная дисперсия равна 0, т.е. задача имеет точное математическое решение. Обычно суммарная дисперсия признаков раскладывается таким образом, что первые несколько компонент уже объясняют большую долю этой дисперсии, а остальные почти ничего не добавляют, поэтому совсем не обязательно выделение всех компонент.

Факторный анализ: выбор факторов

- 1. Если факторов окажется столько же, сколько исходных переменных, факторный анализ теряет смысл, поскольку его целью является сокращение исходного набора переменных.**
- 2. Необходимо принять решение, какие из факторов следует оставить для дальнейшего анализа. Для этого исследователи пользуются следующими критериями:**
 - формальные критерии - все факторы, чьи собственные значения превышают единицу, сохраняются для дальнейшего анализа**
 - критерий «каменистой осыпи» Р. Кеттелла - состоит в поиске точки, где убывание собственных значений замедляется наиболее сильно.**
- 3. В любом случае, окончательное решение о числе факторов обычно принимается после интерпретации факторов, следовательно, факторный анализ предполагает неоднократное выделение различного числа факторов.**

Факторный анализ: значения факторов

После интерпретации факторов необходимо вычислить их значения. Факторный анализ имеет собственную ценность. Однако если цель факторного анализа заключается в снижении исходного числа переменных до небольшого набора составных переменных (факторов), которые в дальнейшем используются в многомерном анализе, то имеет смысл вычислить для каждого респондента значение фактора. Фактор представляет собой линейную комбинацию исходных переменных. Значение для f i -го фактора можно вычислить по формуле:

$$F_i = b_{i1}X_1 + b_{i2}X_2 + \dots + b_{ik}X_k$$

Факторный анализ: факторная матрица

Собственные значения

Суммарная объясненная дисперсия

Объясненная совокупная дисперсия


Компонент	Начальные собственные значения			Суммы квадратов нагрузок извлечения		
	Всего	% дисперсии	Суммарный %	Всего	% дисперсии	Суммарный %
1	1,392	9,278	9,278	1,392	9,278	9,278
2	1,293	8,623	17,901	1,293	8,623	17,901
3	1,234	8,224	26,125	1,234	8,224	26,125
4	1,155	7,701	33,826	1,155	7,701	33,826
5	1,091	7,274	41,100	1,091	7,274	41,100
6	1,065	7,098	48,198	1,065	7,098	48,198
7	1,052	7,011	55,209	1,052	7,011	55,209
8	,953	6,353	61,561			
9	,940	6,269	67,831			
10	,900	6,002	73,833			
11	,855	5,699	79,532			
12	,817	5,450	84,982			
13	,784	5,224	90,206			
14	,762	5,079	95,284			
15	,707	4,716	100,000			

Количество факторов

Количество выбранных факторов

Факторный анализ: выбор факторов



Метод «каменистой осыпи»



Факторный анализ: факторная диаграмма

Целью вращения является получение простой структуры, которой соответствует большое значение нагрузки каждой переменной только по одному фактору и малое по всем остальным факторам. Нагрузка отражает связь между переменной и фактором, являясь подобием коэффициента корреляции. Значение нагрузки лежит в пределах $(-1; 1)$.

- До вращения точки, соответствующие переменным, расположены на удалении от осей факторов.
- После поворота осей переменные оказываются вблизи осей, что соответствует максимальной нагрузке каждой переменной только по одному фактору.



Факторный анализ: выбор факторов

- Коэффициент взаимосвязи между некоторым признаком (X) и общим фактором (F), выражающий меру влияния фактора на признак – факторная нагрузка данного признака по данному общему фактору.
- Матрица, состоящая из факторных нагрузок и имеющая число столбцов, равная числу общих факторов, и число строк равное числу исходных признаков, называется факторной матрицей. Факторная матрица фиксирует степень линейной связи каждого признака с каждым общим фактором.
- Величина факторной нагрузки не превышает по модулю 1, а знак говорит о положительной/отрицательной связи признака с фактором. Значение факторной нагрузки, близкое к нулю – фактор практически не влияет на данный признак.
- Можно вычислить вклады факторов в общую дисперсию всех признаков (путем вычисления суммы квадратов факторных нагрузок для каждого фактора по всем признакам). Чем выше доля этого вклада в общей дисперсии, тем более значимым является данный фактор.

Оценка качества модели в ФА

- Критерий сферичности Бартлетта — показатель, с помощью которого проверяют, отличаются ли корреляции от 0. Если r близко к нулю, то выбранная переменная не взаимосвязана с другими. Значимость меньше 0,05 указывает на то, что проведение факторного анализа приемлемо.
- Корреляционная матрица — матрица, включающая в себя все возможные коэффициенты корреляций r между анализируемыми переменными.
- КМО — мера адекватности выборки Кайзера—Мейера—Олкина — величина, используемая для оценки применимости факторного анализа. Значения от 0,5 до 1 говорят об адекватности факторного анализа, значения до 0,5 указывают на то, что факторный анализ неприменим к выборке.
- Графическое изображение критерия “каменистой осыпи” — график собственных значений факторов, расположенных в порядке убывания, используется для определения достаточного числа факторов.

Оценка качества модели в ФА

Критерий адекватности выборки Кайзера-Мейера-Олкина (КМО) – величина, характеризующая степень применимости факторного анализа к данной выборке.

Правило интерпретации этого критерия:

- $\geq 0,9$ - безусловная адекватность
- $[0,8; 0,9)$ - высокая адекватность
- $[0,7; 0,8)$ - приемлемая адекватность
- $[0,6; 0,7)$ - удовлетворительная адекватность
- $[0,5; 0,6)$ - низкая адекватность
- $< 0,5$ - факторный анализ неприменим к выборке.

Факторный анализ и многомерное шкалирование

Если распределение не нормальное, связь переменных нелинейная, выборка небольшая, то используем:

Многомерное шкалирование (MultiDimensional Scaling - MDS)

На основе сходства (любых дистанций) между наблюдениями позволяет расположить их в пространстве нескольких новых факторов так, чтобы факторы объясняли как можно больше изменчивости.

Многомерное шкалирование и факторный анализ

Но если данные более-менее удовлетворяют требованиям факторного анализа, лучше проводить его, так как:

- 1. Факторный анализ - гораздо более мощная процедура, намного лучше оценивает связи исходных переменных**
- 2. Результаты гораздо проще интерпретировать: в многомерном шкалировании очень трудно объяснить, что же значат полученные факторы**