

ТЕХНОЛОГИИ ХРАНЕНИЯ БОЛЬШИХ ДАННЫХ

Многомерный Статистический Анализ

.....

Дискриминантный анализ: понятие

Дискриминантный анализ – раздел многомерного статистического анализа, который позволяет предсказать принадлежность объектов к двум или более непересекающимся группам.

- **исходными данными для дискриминантного анализа является множество объектов, разделенных на группы так, что каждый объект может быть отнесен только к одной группе. Для каждого из объектов имеются данные по ряду количественных переменных. Такие переменные называются дискриминантными переменными или предикторами.**

Задачами дискриминантного анализа является определение:

- **решающих правил, позволяющих по значениям дискриминантных переменных (предикторов) отнести каждый объект к одной из известных групп.**
- **«веса» каждой дискриминантной переменной для разделения объектов на группы.**

Дискриминантный анализ: функция

Ядром дискриминантного анализа является построение так называемой дискриминантной функции:

$$d = b_1x_1 + b_2x_2 + \dots + b_nx_n + a$$

x_1 и x_n — значения переменных, соответствующих рассматриваемым случаям.

$b_1 - b_n$ и a — коэффициенты, которые и предстоит оценить с помощью дискриминантного анализа.

Необходимо определить такие коэффициенты, чтобы по значениям дискриминантной функции можно было с максимальной четкостью провести разделение по группам. Затем на основе этого же правила отнести (предсказать) респондента или множество респондентов к «свойственной» им группе.

Дискриминантный анализ: примеры

Примеры использования дискриминантного анализа:

- подходит ли соискатель работы для той или иной должности?
- отличаются ли в потреблении замороженных продуктов покупатели, которые пьют безалкогольные напитки мало, умеренно и много?
- какие факторы влияют на увеличение риска пациента получить сердечный приступ?
- какие психографические характеристики помогают провести различия между восприимчивыми и не восприимчивыми к цене покупателями компьютерной техники?
- различаются ли между собой сегменты рынка по своим предпочтениям к средствам массовой информации?

Дискриминантный анализ: виды

Дискриминантный анализ для двух групп



(two-group discriminant analysis) -
зависимая переменная имеет
две категории

Множественный дискриминантный анализ



(multiple discriminant analysis) - у
зависимой переменной имеется
три или больше категорий

Дискриминантный анализ: цель

Целью дискриминантного анализа является разделение совокупности объектов на несколько более мелких групп.

Процесс классификации в дискриминантном анализе - изначально заданы количество и состав классов, и основная задача заключается в определении того, насколько точно можно предсказать принадлежность объектов к классам при помощи данного набора дискриминантных переменных (предикторов).

- **предсказание значения «зависимой» функции (в данном случае — категории номинального признака).**
- **определение, какие «независимые» переменные лучше всего подходят для такого предсказания.**

Дискриминантный анализ: уравнение

Дискриминантный анализ основан на составлении уравнения регрессии, использующего номинальную зависимую переменную (не является количественной, а номинальной).

- **уравнение регрессии составляется на основе тех объектов, о которых известна групповая принадлежность, что позволяет максимально точно подобрать его коэффициенты.**
- **после того как уравнение регрессии получено, его можно использовать для группировки интересующих нас объектов в целях прогнозирования их принадлежности к какому-либо классу.**

Дискриминантный анализ: условия

1. Зависимая переменная должна быть категориальной (номинальной), а предикторы (независимые переменные) - интервальными.
2. Необходимо наличие «тестовой» или проверочной (Validation sample) выборки и соответствие ее анализируемой выборке (Analysis sample).

Дискриминантный анализ: этапы

Процедура дискриминантного анализа состоит из следующих стадий:

- 1. Разделение выборки на две части.**
- 2. Выбор переменных – предикторов.**
- 3. Вычисление параметров дискриминантной функции.**
- 4. Интерпретация результатов.**

Дискриминантный анализ: разделение выборки

Анализируемая выборка (analysis sample)



Часть общей выборки, которую используют для вычисления дискриминантной функции.

Проверочная выборка (validation sample)



Часть общей выборки, которую используют для проверки результатов расчета на основании анализируемой выборки.

Дискриминантный анализ: выбор переменных

Если число переменных достаточно велико (например, несколько сотен), то не представляется возможным применить дискриминантный анализ ко всем переменным одновременно.

Поэтому:

- на начальном этапе дискриминантного анализа для предикторов формируется корреляционная матрица.
- помимо корреляционной матрицы можно также вычислить ковариационные матрицы для отдельных групп, для всей выборки либо общую внутригрупповую ковариационную матрицу

Кроме того:

- нередко исследователи применяют серию t-критериев между двумя группами для каждой переменной либо однофакторный дисперсионный анализ, если число групп оказывается больше двух

Поскольку целью дискриминантного анализа является составление наилучшего уравнения регрессии, дополнительный анализ исходных данных никогда не является лишним.

Дискриминантный анализ: вычисление функции

Метод принудительного включения (direct method):
дискриминантную функцию вычисляют при одновременном введении всех предикторов. В этом случае учитывается каждая независимая переменная.

Метод принудительного включения

Задача: Спрогнозировать, какая часть населения действительно считает, что их голос может повлиять на результаты выборов, а какая нет

Анализ сводки обработки наблюдений

Невзвешенные наблюдения		N	Проценты
Допустимо		1132	100,0
Исключено	Отсутствующие или выходящие за пределы диапазона коды групп	0	,0
	По крайней мере одна дискриминирующая переменная	0	,0
	И отсутствующие или выходящие за пределы диапазоны коды групп, и по крайней мере одна дискриминирующая переменная	0	,0
	Всего	0	,0
Всего		1132	100,0

- Всего 1132 наблюдения.
- Отсутствуют исключенные из анализа наблюдения.
- Таким образом, для всех наблюдений проведен дискриминантный анализ.

Метод принудительного включения

Таблица позволяет увидеть, являются ли предикторы независимыми посредством сопоставления коэффициентов корреляции.

Приведенные коэффициенты – это средние коэффициенты двух исследуемых групп. Их значения не должны превышать 0,5 (корреляция должна отсутствовать).

Объединенные внутригрупповые матрицы

		Сколько Вам лет (укажите полное число лет)?	Какое у Вас образование ?	Как за последний год изменилась Ваша жизнь и ее отдельные стороны? - Ваша жизнь в целом	По Вашему мнению, как работают следующие органы власти: хорошо или плохо? - Президент
Корреляция	Сколько Вам лет (укажите полное число лет)?	1,000	-,147	,008	-,063
	Какое у Вас образование?	-,147	1,000	,013	-,067
	Как за последний год изменилась Ваша жизнь и ее отдельные стороны? - Ваша жизнь в целом	,008	,013	1,000	,089
	По Вашему мнению, как работают следующие органы власти: хорошо или плохо? - Президент	-,063	-,067	,089	1,000

Метод принудительного включения

Нестандартизированные (канонические) коэффициенты дискриминантной функции – это множители при заданных значениях переменных, входящих в дискриминантную функцию.

Коэффициенты канонической дискриминантной функции	
	Функция
	1
Сколько Вам лет (укажите полное число лет)?	,046
Какое у Вас образование?	,478
Как за последний год изменилась Ваша жизнь и ее отдельные стороны? - Ваша жизнь в целом	,022
По Вашему мнению, как работают следующие органы власти: хорошо или плохо? - Президент	-,013
(Константа)	-3,469

Нестандартизированные
коэффициенты

$$D = -3,469 + 0,046x + 0,478y + 0,022z - 0,013t$$

где:

- x – возраст респондента
- y – образование респондента
- z – «Как изменилась ваша жизнь в целом?»
- t – «По Вашему мнению, как работают следующие органы власти? – Президент»

На основе построенной дискриминантной модели можно сделать прогноз о том, какая часть населения считает, что ее голос важен при проведении выборов.

Метод принудительного включения

Результаты классификации^а

А какое из этих утверждений Вам ближе?			Предсказанная принадлежность к группе		Всего
			Мой голос никак не влияет на результаты выборов	Мой голос оказывает важное влияние на результаты выборов	
Исходный	Количество	Мой голос никак не влияет на результаты выборов	145	126	271
		Мой голос оказывает важное влияние на результаты выборов	359	502	861
	%	Мой голос никак не влияет на результаты выборов	53,5	46,5	100,0
		Мой голос оказывает важное влияние на результаты выборов	41,7	58,3	100,0

а. 57,2% исходных сгруппированных наблюдений классифицированы правильно.

- Показывает % верно классифицированных случаев.
- Точность прогнозов составляет 57,2%.

Дискриминантный анализ: вычисление функции

Пошаговый дискриминантный анализ:

- предикторы вводятся последовательно, в зависимости от их способности различить группы.
- основан на минимизации коэффициента Уилкса (λ) после включения в уравнение регрессии каждого нового предиктора.
- Лямбда Уилкса (Wilks' Lambda) – это критерий, используемый при проведении теста и показывающий, значимо ли различаются между собой средние значения дискриминантной функции в исследуемых группах.
 - Если значимость $< 0,05$, то средние двух групп значимо различаются, т.е. доказано наличие дискриминирующих особенностей этих переменных.
 - Если значимость $> 0,05$, то убираем предикторы из анализа.
- этот метод лучше применять в ситуации, когда исследователь хочет отобрать подмножество предикторов для включения их в дискриминантную функцию.

Дискриминантный анализ: интерпретация результатов

Целью дискриминантного анализа является составление уравнения регрессии с использованием выборки, для которой известны значения и предикторов, и критерия. Это уравнение позволяет по известным значениям предикторов определить неизвестные значения критерия для другой выборки.

Дискриминантную функцию рассчитывают для объектов, изначально разделённых на группы.

Подставляя в классификационные функции значения переменных для объекта, можно для него посчитать их значение (classification score) и отнести в ту или иную группу - предсказать, к какой группе он относится, и оценить точность предсказания!

Пошаговый дискриминантный анализ

В таблице «Переменные для анализа» представлены переменные, которые будут использоваться дальше.

В таблице «Переменные не для анализа» представлены порядок исключения переменных и сами исключенные переменные.

Переменные для анализа

Шаг		Допуск	F для удаления	Лямбда Уилкса
1	Сколько Вам лет (укажите полное число лет)?	1,000	11,792	
2	Сколько Вам лет (укажите полное число лет)?	,996	10,779	,995
	По Вашему мнению, как работают следующие органы власти: хорошо или плохо? - Президент	,996	4,564	,990

Переменные не для анализа

Шаг		Допуск	Мин. Допуск	F для ввода	Лямбда Уилкса
0	Сколько Вам лет (укажите полное число лет)?	1,000	1,000	11,792	,990
	Какое у Вас образование?	1,000	1,000	2,491	,998
	Как за последний год изменилась Ваша жизнь и ее отдельные стороны? - Ваша жизнь в целом	1,000	1,000	1,190	,999
	По Вашему мнению, как работают следующие органы власти: хорошо или плохо? - Президент	1,000	1,000	5,565	,995
1	Какое у Вас образование?	,978	,978	4,385	,986
	Как за последний год изменилась Ваша жизнь и ее отдельные стороны? - Ваша жизнь в целом	1,000	1,000	1,119	,989
	По Вашему мнению, как работают следующие органы власти: хорошо или плохо? - Президент	,996	,996	4,564	,986
2	Какое у Вас образование?	,973	,973	3,729	,982
	Как за последний год изменилась Ваша жизнь и ее отдельные стороны? - Ваша жизнь в целом	,992	,988	1,567	,984

Пошаговый дискриминантный анализ

**Коэффициенты канонической
дискриминантной функции**

	Функция
	1
Сколько Вам лет (укажите полное число лет)?	,048
По Вашему мнению, как работают следующие органы власти: хорошо или плохо? - Президент	-,015
(Константа)	-1,922

$$D = -1,922 + 0,048x - 0,015t$$

Пошаговый дискриминантный анализ

Результаты классификации^а

А какое из этих утверждений Вам ближе?			Предсказанная принадлежность к группе		Всего
			Мой голос никак не влияет на результаты выборов	Мой голос оказывает важное влияние на результаты выборов	
Исходный	Количество	Мой голос никак не влияет на результаты выборов	152	119	271
		Мой голос оказывает важное влияние на результаты выборов	391	470	861
	%	Мой голос никак не влияет на результаты выборов	56,1	43,9	100,0
		Мой голос оказывает важное влияние на результаты выборов	45,4	54,6	100,0

а. 54,9% исходных сгруппированных наблюдений классифицированы правильно.

Точность прогноза составляет **54,9%**, хуже, чем при методе принудительного включения