


ТЕХНОЛОГИИ ХРАНЕНИЯ БОЛЬШИХ ДАННЫХ

Многомерный Статистический Анализ

.....

Алгоритмы Машинного Обучения



Кластерный анализ: понятие

- Кластерный анализ предназначен для разбиения исходных данных на поддающиеся интерпретации группы, таким образом, чтобы элементы, входящие в одну группу были максимально «схожи», а элементы из разных групп были максимально «отличными» друг от друга.
- Кластерный анализ – группа методов, используемых для классификации объектов или событий в относительно гомогенные (однородные) группы, которые называют кластерами (clusters).
- Цель – объединить эти объекты в группы, внутри которых они будут более сходными, чем объекты из разных групп.
- Результат – получение дендрограммы (иерархического дерева) – только картинка, никакой проверки гипотез и прочего.

Кластерный анализ: понятие

- В факторном анализе группируются столбцы, т.е. цель – анализ структуры множества признаков и выявление обобщенных факторов.
- В кластерном анализе – группируются строки, т.е. цель – анализ структуры множества объектов.
- Кластерный анализ выполняет кластеризацию объектов.
- Каждый объект – точка в пространстве признаков.
- Задача кластерного анализа – выделение «сгущений» точек, разбиение совокупности на однородные подмножества объектов (сегментация).

Кластерный анализ: понятие

Кластерный анализ в теории



Кластерный анализ: понятие

Кластерный анализ на практике



Кластерный анализ: виды

КЛАСТЕРНЫЙ АНАЛИЗ

```
graph TD; A[КЛАСТЕРНЫЙ АНАЛИЗ] --> B[Иерархический]; A --> C[Анализ к-средних];
```

Иерархический

При маленьком количестве
наблюдений

Объекты по одному присоединяются к кластеру и он становится всё больше и больше

Анализ к-средних

При большом количестве
наблюдений

Объекты присоединяются по одному, но кластеры перегруппировываются в процессе анализа

Иерархический кластерный анализ: понятие

- Каждое наблюдение образует сначала свой отдельный кластер.
- На первом шаге анализа два соседних кластера объединяются в один.
- Этот процесс продолжается до тех пор, пока не останутся только два кластера.
- Расстояние между кластерами является средним значением всех расстояний между всеми возможными парами точек из обоих кластеров.


Иерархический кластерный анализ: этапы



Иерархический кластерный анализ: расстояния

Самой распространенной мерой для определения расстояния между двумя точками на плоскости, образованной координатными осями x и y , является Евклидова мера.

Благодаря возведению в квадрат лучше учитываются большие разности. Эта мера должна всегда использоваться при построении кластеров центроидным, медианным методом или методом Варда.



$$d(X, Y) = \sum_{i=1}^m (X_i - Y_i)^2$$

Иерархический кластерный анализ: расстояния

Расстояние Чебышева – вычисление расстояния как максимума абсолютного значения разности между элементами. Используется при определении двух объектов как "различные", если они отличаются по какому-то одному измерению.

Расстояние Минковского – равно корню в степени из суммы абсолютных разностей пар значений взятых в степени. Степень разности значений можно выбрать в пределах от 1 до 4. Если эту степень взять равной 2, то получим евклидово расстояние.

Расстояние Манхэттена или Хемминга - определяется суммой абсолютных разностей пар значений.




Иерархический кластерный анализ: расстояния

Евклидово расстояние	$d_{Eij} = \left(\sum_{l=1}^m (x_i^l - x_j^l)^2 \right)^{1/2}$
Квадрат Евклидового расстояния	$d_{Eij}^2 = \sum_{l=1}^m (x_i^l - x_j^l)^2$
Расстояние Минковского	$d_{p_{ij}} = \left(\sum_{l=1}^m (x_i^l - x_j^l)^p \right)^{1/p}$
Расстояние Чебышева	$d_{ij} = \max_{1 \leq l \leq l} x_i^l - x_j^l $
Манхэттенское расстояние	$d_H(x_i, x_j) = \sum_{l=1}^k x_i^l - x_j^l $

Иерархический кластерный анализ: кластеризация

Метод кластеризации – это способ вычисления расстояний между кластерами. Существуют следующие основные методы кластеризации:

- Межгрупповая связь (Between-groups linkage)
- Внутригрупповая связь (Within-groups linkage)
- Ближайший сосед (Nearest neighbor)
- Самый дальний сосед (Furthest neighbor)
- Центроидная кластеризация (Centroid clustering)
- Медианная кластеризация (Median clustering)
- Метод Варда (Уорда) (Ward's method)



Иерархический кластерный анализ: расстояния

- **Межгрупповая связь (Between-groups linkage)** - дистанция между кластерами, которая равна среднему значению всех расстояний между всеми возможными парами точек из обоих кластеров. Информация, необходимая для расчёта дистанции, находится на основании всех теоретически возможных пар наблюдений.
- **Внутригрупповая связь (Within-groups linkage)** - дистанция между двумя кластерами рассчитывается на основании всех возможных пар наблюдений, принадлежащих обоим кластерам, причём учитываются также и пары наблюдений, образующиеся внутри кластеров.
- **Ближайший сосед (Nearest neighbor)** - дистанция между двумя кластерами определяется как расстояние между парой наблюдений, расположенных друг к другу ближе всего, причём каждое наблюдение берётся из своего кластера.

Иерархический кластерный анализ: расстояния

- Самый дальний сосед (Furthest neighbor) - дистанция между двумя кластерами определяется как расстояние между самыми удалёнными друг от друга значениями наблюдений, причём каждое наблюдение берётся из своего кластера.
- Центроидная кластеризация (Centroid clustering) - в обоих кластерах рассчитываются средние значения переменных относящихся к ним наблюдений. Затем расстояние между двумя кластерами рассчитывается как дистанция между двумя усредненными наблюдениями.
- Медианная кластеризация (Median clustering) - тот же центроидный метод, но центр объединенного кластера вычисляется как среднее всех объектов.
- Метод Варда (Ward-Method) - сначала в обоих кластерах для всех имеющихся наблюдений производится расчёт средних значений отдельных переменных. Затем вычисляются квадраты евклидовых расстояний от отдельных наблюдений каждого кластера до этого кластерного среднего значения. Эти дистанции суммируются. Потом в один новый кластер объединяются те кластеры, которые дают наименьший прирост общей суммы дистанций.

Иерархический кластерный анализ: стандартизация

Согласно формуле евклидовой меры, переменная, имеющая большие значения, практически полностью доминирует над переменной с малыми значениями.


Для решения этой проблемы используется z-преобразование (стандартизация) значений переменных, которое приводит значения всех преобразованных переменных к единому диапазону значений.

Z-стандартизация	Из значений вычитается среднее и затем они делятся на стандартное отклонение.
Разброс от -1 до 1	Линейным преобразованием переменных добиваются разброса значений от -1 до 1
Разброс от 0 до 1	Линейным преобразованием переменных добиваются разброса значений от 0 до 1
Максимум 1	Значения переменных делятся на их максимум
Среднее 1	Значения переменных делятся на их среднее
Стандартное отклонение 1	Значения переменных делятся на стандартное отклонение

Иерархический кластерный анализ: кластеры

1. Необходимо руководствоваться практическими и теоретическими соображениями. Исходя из цели исследования, например, может быть необходимо три кластера.
2. В иерархической кластеризации в качестве критерия используются расстояния. Необходимо смотреть на коэффициент в протоколе объединения (расстояние между двумя кластерами, определенное на основании выбранной дистанционной меры с учётом предусмотренного преобразования значений).
 - Когда мера расстояния между двумя кластерами увеличивается скачкообразно, процесс объединения в новые кластеры необходимо остановить. Иначе будут объединены кластеры, находящиеся на большом расстоянии друг от друга.
 - Оптимальным считается число кластеров равное разности количества наблюдений и количества шагов, после которого коэффициент увеличивается скачкообразно.
3. Размеры кластеров должны быть значимыми.

Иерархический кластерный анализ: дендрограмма




Иерархический кластерный анализ: оценка качества

- Необходимо выполнять кластерный анализ одних и тех же данных, но с использованием различных способов измерения расстояния.
- Сравнить результаты, полученные на основе различных способов расстояния, чтобы определить, насколько совпадают полученные результаты.
- Разбить данные на две равные части случайным образом. Выполнить кластерный анализ отдельно для каждой половины. Сравнить кластерные центроиды двух подвыборок.
- Случайным образом удалить некоторые переменные. Выполнить кластерный анализ по сокращенному набору переменных. Сравнить результаты с полученными на основе полного набора переменных.

Кластерный анализ: метод k-средних

Кластеризация K-средних – метод разделения множества данных на K различных непересекающихся кластеров. Для выполнения кластеризации сначала нужно определить желаемое число кластеров K, затем алгоритм K-средних будет относить каждое наблюдение в точности к одному из K кластеров.



Кластерный анализ: метод k-средних

Следующий алгоритм находит локальный минимум задачи – достаточно хорошее решение.

1. Произвольным образом присваиваем номер от 1 до K каждому из наблюдений. Это послужит начальным разделением на классы.

2. Повторяем, пока разбиение на классы не перестанет меняться:

- **Для каждого из K кластеров вычисляем кластерный центроид. Центроид k -го кластера – это вектор средних p характеристик для наблюдений в k -м кластере.**
- **Относим каждое наблюдение к тому кластеру, чей центроид ближайший (где ближайший определяется с использованием Евклидова расстояния)**

Кластерный анализ: метод k-средних

Сначала определяется центр кластера, а затем группируют все объекты в пределах заданного от центра порогового значения.

Недостатки:

- Чувствительность к выбросам
- Необходимо заранее задавать количество кластеров, а не как в иерархическом анализе, получать это в качестве результата

Проблему с выбором числа кластеров можно преодолеть проведением иерархического анализа со случайно отобранной выборкой наблюдений и, таким образом, определить оптимальное количество кластеров.

Достоинства:

- Простота использования
- В качестве метрики используется Евклидово расстояние
- Возможность наглядной интерпретации кластеров с использованием графика «Средних значений в кластерах»

Кластерный анализ: требования к выборкам


- 1. В качестве исходных данных можно взять любую матрицу дистанций – никаких ограничений и требований к выборке.**
- 2. Нет необходимости исключать аутлаеры.**
- 3. Переменные, измеренные в разных шкалах, должны быть стандартизированы.**

Кластеризация методом К-средних

Ставим три ларька с шаурмой оптимальным образом
(иллюстрируя метод К-средних)




1. Ставим ларьки с шаурмой в случайных местах



2. Смотрим в какой кому ближе идти




3. Двигаем ларьки ближе к центрам их популярности



4. Снова смотрим и двигаем



5. Повторяем много раз



6. Готово, вы великолепны!